



INSTITUT
POLYTECHNIQUE
DE PARIS

ÉCOLE POLYTECHNIQUE

RAPPORT FINAL APM_52065

Modélisation aléatoire et statistique des processus

Travail réalisé par :

Joel Tagne W. — *École polytechnique, Mathématiques appliquées*

Hok Seng — *École polytechnique, Mathématiques appliquées*

Christel Mallo P. — *École polytechnique, Mathématiques appliquées*

29 août 2026

Résumé

Ce rapport, réalisé dans le cadre du cours *Modélisation aléatoire et statistique des processus*, présente trois applications de la modélisation probabiliste et statistique à des problématiques issues de la finance et de la modélisation spatio-temporelle. Dans une première partie, nous étudions la dynamique du contrat à terme sur l'or $GC = F$ et proposons une modélisation de sa volatilité par un modèle GARCH(1,1)-Student, afin de produire une prévision hors échantillon de la volatilité pour mars 2026. Dans une deuxième partie, nous considérons un processus de Hawkes spatio-temporel multivarié pour modéliser la criminalité à Chicago, en tenant compte de mécanismes d'auto-excitation et d'excitation croisée entre vols et agressions. Enfin, nous analysons la dépendance entre les indices de volatilité implicite VIX et RVX à l'aide de copules, puis construisons une stratégie de *pair trading* fondée sur les probabilités conditionnelles issues du modèle ajusté. L'ensemble du travail illustre comment des outils issus des processus stochastiques, de l'inférence statistique et de l'optimisation numérique peuvent être mobilisés pour décrire, prévoir et exploiter des dynamiques complexes dans des contextes appliqués variés.

Mots-clés : volatilité stochastique, GARCH, processus de Hawkes, copules, pair trading, modélisation spatio-temporelle.

Table des matières

1	Prévision de la tendance et de la volatilité du contrat a terme sur l'or (GC=F) pour mars 2026	3
1.1	Analyse de Données	3
1.1.1	Description des données	3
1.1.2	Analyse exploratoire	3
1.1.3	Test De Stationnarité	4
1.1.4	Analyse de l'autocorrélation	4
1.1.5	Test de Jarque-Bera	4
1.1.6	Modèle de volatilité	5
1.2	Modélisation de la volatilité : modèle GARCH(1,1)	5
1.2.1	Estimation des paramètres par maximum de vraisemblance	6
1.2.2	Prévision de la volatilité pour mars 2026	7
2	Processus de Hawkes spatio-temporels pour la modélisation de la criminalité	9
2.1	Processus de Hawkes spatio-temporels	9
2.1.1	Extension spatio-temporelle	9
2.2	Données et prétraitement	10
2.2.1	Description du jeu de données	10
2.2.2	Prétraitement	11
2.2.3	Log-vraisemblance du processus ponctuel spatio-temporel	12
2.2.4	Méthode d'optimisation	12
2.3	Résultats et discussion	12
2.3.1	Paramètres estimés	12
3	Analyse de dépendance et stratégie de pair trading sur les indices <i>VIX</i> et <i>RVX</i>	15
3.1	Présentation théorique des copules	15
3.1.1	Définition et intérêt des copules en finance	15
3.1.2	Copules considérées	15
3.2	Description des données	16
3.3	Méthodologie statistique	16
3.3.1	Ajustement des marges	16
3.3.2	Sélection de la copule	17
3.4	Construction de la stratégie de pair trading	18
3.4.1	Probabilités conditionnelles, règles de trading et rendement	18
3.5	Résultats empiriques	19
3.5.1	Performances	19

1 Prévision de la tendance et de la volatilité du contrat à terme sur l'or (GC=F) pour mars 2026

Récemment, le contexte international a été marqué par des tensions géopolitiques entre l'Iran, les États-Unis et Israël. Ce type d'événements peut influencer fortement les marchés financiers et entraîner des variations importantes du prix de l'or, souvent considéré comme une valeur refuge en période d'incertitude.

Dans cette première partie, nous étudions la modélisation et la prévision de la volatilité de GC=F, le contrat à terme sur l'or. L'objectif est d'analyser le comportement de cette série financière et de mettre en évidence ses principales propriétés statistiques, telles que la stationnarité, l'auto-corrélation et l'hétéroscédasticité. Nous présenterons ensuite le modèle adapté à l'étude de la volatilité financière, notamment le modèle GARCH, afin de retenir la spécification la plus appropriée. Enfin, après estimation et calibration du modèle choisi, nous procéderons à une prévision de la volatilité pour le mois de mars 2026.

1.1 Analyse de Données

1.1.1 Description des données

Les données utilisées dans ce projet proviennent de Yahoo Finance et concernent le contrat à terme sur l'or GC=F. La période étudiée va de janvier 2025 à février 2026, avec une fréquence journalière. Pour la modélisation, nous nous intéressons principalement au prix de clôture ainsi qu'aux rendements calculés à partir de ce prix.

1.1.2 Analyse exploratoire

Dans un premier temps, une analyse graphique des séries est réalisée afin de mieux comprendre l'évolution du prix de l'or et le comportement de ses rendements au cours de la période étudiée. La Figure 1 présente, à gauche, l'évolution journalière du prix de clôture du contrat à terme sur l'or GC=F et, à droite, l'évolution des log-rendements journaliers. Le graphique des prix met en évidence une tendance générale haussière, ce qui suggère que la série en niveau n'est pas stationnaire. En revanche, les log-rendements fluctuent autour de 0, sans tendance haussière de long terme évidente. Cela suggère que la série des rendements est beaucoup plus proche d'être stationnaire que la série des prix. En plus, la variance n'est pas constant dans le temps




FIGURE 1 – Evolution du prix journalier




FIGURE 2 – Evolution des log-rendements journaliers

1.1.3 Test De Stationnarité

Pour précéder à la modélisation, il est essentiel de vérifier la stationnarité des séries, nous appliquons le test de Dickey-Fuller augmenté (ADF) au prix, à sa première différence ainsi qu'aux log-rendements. Les résultats montrent que la série de prix n'est pas stationnaire en niveau, puisque la p-value obtenue est égale à 0.988443, ce qui ne permet pas de rejeter l'hypothèse nulle de racine unitaire. En revanche, la première différence et les log-rendements apparaissent stationnaires, avec des p-values inférieures à 0.001.

1.1.4 Analyse de l'autocorrélation

Afin d'examiner la dépendance linéaire dans la série des log-rendements de 'GC=F', nous analysons les fonctions d'autocorrélation simple (ACF) et partielle (PACF), présentées à la Figure 3. Dans l'ensemble, la majorité des retards se situent à l'intérieur des bandes de confiance, ce qui indique l'absence d'autocorrélations statistiquement significatives pour la plupart des lags. Cela suggère que les log-rendements contiennent peu de structure linéaire dans l'équation de moyenne.




FIGURE 3 – Fonctions d'autocorrélation simple et partielle des log-rendements de GC=F

Cette impression graphique est confirmée par le test de Ljung-Box, appliqué aux lags 10, 20 et 30. Les p-values obtenues sont respectivement de 0.5517, 0.7840 et 0.9149, toutes largement supérieures au seuil de '5%'. Par conséquent, nous ne rejetons pas l'hypothèse nulle d'absence d'autocorrélation. Ces résultats montrent que les log-rendements se comportent approximativement comme un bruit blanc dans l'équation de moyenne, ce qui signifie que les valeurs passées apportent peu d'information utile pour prévoir directement la moyenne future de la série.

1.1.5 Test de Jarque-Bera

Avant de procéder à la modélisation de la volatilité, il est utile de vérifier si les rendements et les résidus suivent une loi normale. Pour cela, nous appliquons le test de Jarque-Bera à la série des log-rendements ainsi qu'aux résidus du modèle ARIMA(1,0,1). Ce test permet d'évaluer la normalité d'une série en s'appuyant sur l'asymétrie et l'aplatissement.

Les résultats obtenus montrent que l'hypothèse nulle de normalité est fortement rejetée dans les deux cas. En effet, la p-value obtenue pour les log-rendements est inférieure à 0.001, tout comme celle des résidus du modèle ARIMA(1,0,1). Ces résultats indiquent que la distribution des rendements et des résidus s'écarte significativement d'une loi normale. Par conséquent, l'hypothèse d'erreurs gaussiennes n'est pas adaptée aux données.

étudiées. Cela justifie l'utilisation d'une distribution plus flexible, comme la loi de Student, dans la modélisation de la volatilité par un modèle GARCH.

1.1.6 Modèle de volatilité

Pour le modélisation de volatilité, nous utilisons le modèle *Generalized Autoregressive Conditional Heteroskedasticity* (GARCH), ce qui est une extension du modèle ARCH. Développé par Tim Bollerslev, il généralise l'approche en incluant à la fois les résidus passés au carré et les variances conditionnelles passées. Mathématiquement, un modèle GARCH(p, q) est défini par :

$$\varepsilon_t = \sigma_t \eta_t \quad (1)$$

$$\sigma_t^2 = \omega + \sum_{i=1}^q \alpha_i \varepsilon_{t-i}^2 + \sum_{i=1}^p \beta_i \sigma_{t-i}^2 \quad (2)$$

Les conclusions tirées de l'analyse précédente montrent que le modèle GARCH est bien adapté à notre cas d'étude. Plus précisément, nous avons observé que les données présentent les caractéristiques suivantes :

- les log-rendements sont stationnaires, faiblement autocorrélés, et leur distribution présente des queues épaisses ;
- les log-rendements au carré présentent une autocorrélation, ce qui suggère la présence d'une dépendance dans la variance.

Dans la suite, nous retenons donc un modèle GARCH(1,1), qui offre en général un bon compromis entre simplicité et capacité à reproduire la dynamique de volatilité des séries financières.

1.2 Modélisation de la volatilité : modèle GARCH(1,1)

Afin de modéliser l'hétéroscédasticité conditionnelle observée dans les rendements de l'or, nous retenons un modèle de type *Generalized Autoregressive Conditional Heteroskedasticity*, noté **GARCH(1,1)**.

Soit $(r_t)_{t=1, \dots, T}$ la série des rendements logarithmiques, exprimés ici en pourcentage. Le modèle retenu s'écrit sous la forme suivante :

$$r_t = \mu + \varepsilon_t, \quad (3)$$

$$\varepsilon_t = \sigma_t z_t, \quad (4)$$

où :

- μ désigne la moyenne conditionnelle des rendements ;
- ε_t est le choc aléatoire à la date t ;
- σ_t^2 est la variance conditionnelle ;
- (z_t) est une suite i.i.d. centrée réduite, suivant soit une loi normale standard, soit une loi de Student standardisée.

Dans un modèle GARCH(1,1), la dynamique de la variance conditionnelle est donnée par :

$$\sigma_t^2 = \omega + \alpha_1 \varepsilon_{t-1}^2 + \beta_1 \sigma_{t-1}^2, \quad (5)$$

avec les contraintes usuelles :

$$\omega > 0, \quad \alpha_1 \geq 0, \quad \beta_1 \geq 0.$$

Pour assurer l'existence d'une variance inconditionnelle finie et garantir la stationnarité au second ordre, on impose généralement :

$$\alpha_1 + \beta_1 < 1.$$

1.2.1 Estimation des paramètres par maximum de vraisemblance

Les paramètres du modèle

$$\theta = (\mu, \omega, \alpha_1, \beta_1, \nu)$$

(dans le cas Student- t , où ν désigne le nombre de degrés de liberté) sont estimés par **maximum de vraisemblance**.

Conditionnellement à l'information disponible à la date $t - 1$, notée $\mathcal{F}_{t-1}$, on suppose que :

$$r_t \mid \mathcal{F}_{t-1} \sim \mu + \sigma_t z_t.$$

La fonction de vraisemblance conditionnelle s'écrit alors comme le produit des densités conditionnelles :

$$L(\theta) = \prod_{t=1}^T f(r_t \mid \mathcal{F}_{t-1}; \theta),$$

et la log-vraisemblance correspondante est :

$$\ell(\theta) = \sum_{t=1}^T \log f(r_t \mid \mathcal{F}_{t-1}; \theta).$$

Dans le cas d'innovations suivant une loi de Student standardisée, on suppose que

$$r_t \mid \mathcal{F}_{t-1} = \mu + \sigma_t z_t,$$

où

$$z_t \sim t_\nu^*,$$

avec t_ν^* désignant une loi de Student standardisée, centrée et de variance unitaire.

La densité de z_t s'écrit :

$$f_Z(z; \nu) = \frac{\Gamma\left(\frac{\nu+1}{2}\right)}{\Gamma\left(\frac{\nu}{2}\right) \sqrt{(\nu-2)\pi}} \left(1 + \frac{z^2}{\nu-2}\right)^{-\frac{\nu+1}{2}}, \quad \nu > 2.$$

Comme

$$z_t = \frac{r_t - \mu}{\sigma_t},$$

la densité conditionnelle de r_t sachant $\mathcal{F}_{t-1}$ est donnée par :

$$f(r_t \mid \mathcal{F}_{t-1}; \theta) = \frac{1}{\sigma_t} f_Z\left(\frac{r_t - \mu}{\sigma_t}; \nu\right).$$

En remplaçant par l'expression explicite de la densité de Student standardisée, on obtient :

$$f(r_t | \mathcal{F}_{t-1}; \theta) = \frac{\Gamma\left(\frac{\nu+1}{2}\right)}{\Gamma\left(\frac{\nu}{2}\right) \sqrt{(\nu-2)\pi} \sigma_t} \left[1 + \frac{1}{\nu-2} \left(\frac{r_t - \mu}{\sigma_t} \right)^2 \right]^{-\frac{\nu+1}{2}}.$$

En développant, on obtient :

$$\ell(\theta) = \sum_{t=1}^T \left[\log \Gamma\left(\frac{\nu+1}{2}\right) - \log \Gamma\left(\frac{\nu}{2}\right) - \frac{1}{2} \log((\nu-2)\pi) - \log \sigma_t - \frac{\nu+1}{2} \log \left(1 + \frac{1}{\nu-2} \left(\frac{r_t - \mu}{\sigma_t} \right)^2 \right) \right]$$

Les paramètres du modèle sont ensuite estimés par maximum de vraisemblance, c'est-à-dire en résolvant numériquement :

$$\hat{\theta} = \arg \max_{\theta} \ell(\theta),$$

sous les contraintes usuelles du modèle GARCH :

$$\omega > 0, \quad \alpha_1 \geq 0, \quad \beta_1 \geq 0, \quad \alpha_1 + \beta_1 < 1, \quad \nu > 2.$$

Le modèle finalement retenu est donc le **GARCH(1,1)-Student- t** . Les estimations obtenues sont résumées dans le tableau 1.

TABLE 1 – Paramètres estimés du modèle GARCH(1,1)-Student- t

Paramètre	Estimateur	Erreur std.	Statistique t	p -value
μ	0.2753	0.0649	4.242	2.216×10^{-5}
ω	0.1412	0.0629	2.246	0.0247
α_1	0.1363	0.0606	2.250	0.0244
β_1	0.8133	0.0548	14.851	6.849×10^{-50}

On remarque que les paramètres de variance sont statistiquement significatifs aux seuils usuels. En particulier :

- $\omega = 0.1412$ indique un niveau de base positif de la variance conditionnelle ;
- $\alpha_1 = 0.1363$ montre que la volatilité réagit significativement aux chocs récents ;
- $\beta_1 = 0.8133$ met en évidence une forte persistance de la volatilité.

En conclusion, la modélisation GARCH(1,1) met clairement en évidence une dynamique de volatilité persistante dans les rendements de l'or.

1.2.2 Prévision de la volatilité pour mars 2026

Dans cette partie, nous utilisons le modèle estimé pour produire une prévision de la volatilité sur la période de *mars 2026*. L'échantillon est divisé en deux sous-périodes : une période d'apprentissage contenant 290 observations, utilisée pour estimer le modèle, et une période de test contenant 15 observations, utilisée pour évaluer la performance prédictive hors échantillon.

La prévision est réalisée selon une approche *rolling one-step-ahead*, dans laquelle le modèle est réestimé de manière séquentielle afin d'intégrer l'information la plus récente à

chaque date de prévision. Cette méthode permet d'obtenir une prévision plus réactive et mieux adaptée à l'évolution récente de la volatilité.

La qualité de la prévision est évaluée à l'aide de l'erreur quadratique moyenne. Les résultats obtenus montrent une erreur de **0.898** sur l'échantillon d'apprentissage et une erreur de **1.3597** sur l'échantillon de test. Ces résultats indiquent que le modèle fournit une prévision globalement cohérente de la volatilité, même si les mouvements observés en 'mars 2026' restent partiellement difficiles à anticiper.

La Figure 4 compare la volatilité réalisée, la volatilité ajustée en échantillon et la volatilité prévue hors échantillon. On observe que la volatilité prévue demeure plus lisse que la volatilité réalisée. Le modèle reproduit correctement le niveau général du risque, mais il sous-estime encore certaines pointes abruptes de volatilité. Ce comportement est classique pour un modèle GARCH(1,1) standard, qui capte bien la persistance de la volatilité mais réagit plus difficilement aux chocs extrêmes soudains




FIGURE 4 – Comparaison entre la volatilité réalisée, la volatilité ajustée et la volatilité prévue pour mars 2026

2 Processus de Hawkes spatio-temporels pour la modélisation de la criminalité

La prédiction et la compréhension des phénomènes criminels constituent des enjeux majeurs pour les politiques de sécurité publique. Une observation empirique bien documentée dans la littérature criminologique est le phénomène de *near-repeat victimization* : après un crime, la probabilité d'observer un nouveau crime dans un voisinage spatio-temporel proche est significativement plus élevée que la normale. Ce comportement de *contagion* ou d'*auto-excitation* suggère naturellement l'utilisation des processus de Hawkes comme cadre de modélisation.

Dans ce projet, nous proposons d'appliquer un processus de Hawkes spatio-temporel multivarié à la modélisation de la criminalité dans la ville de Chicago. Notre analyse porte sur deux types de crimes : vols (*Theft*) et agressions (*Battery*) pour le mois de décembre 2015.

2.1 Processus de Hawkes spatio-temporels

Le processus de Hawkes est un processus ponctuel auto-excitateur dont l'intensité conditionnelle est de la forme :

$$\lambda(t \mid \mathcal{H}_t) = \mu + \sum_{t_i < t} g(t - t_i),$$

où $\mu > 0$ est l'intensité de fond (*background rate*), supposée constante, et $g : \mathbb{R}^+ \rightarrow \mathbb{R}^+$ est le *noyau d'excitation* (*triggering kernel*), une fonction positive décroissante traduisant l'influence décroissante des événements passés sur l'intensité courante.

Afin de modéliser des phénomènes impliquant K types d'événements distincts en interaction, on considère un *processus de Hawkes multivarié* $(N^1, \dots, N^K)$. Pour chaque type $k \in \{1, \dots, K\}$, l'intensité conditionnelle est :

$$\lambda_k(t \mid \mathcal{H}_t) = \mu_k + \sum_{l=1}^K \alpha_{kl} \sum_{t_i^l < t} g_{kl}(t - t_i^l),$$

où :

- $\mu_k > 0$ est l'intensité de fond du type k ,
- $\alpha_{kl} \geq 0$ quantifie l'influence des événements de type l sur l'intensité du type k ,
- $g_{kl}(\cdot)$ est le noyau d'excitation de la paire (k, l) , normalisé de sorte que $\int_0^{+\infty} g_{kl}(s) ds = 1$.

Dans notre application, $K = 2$ avec les types : *Theft* ($k = 1$), *Battery* ($k = 2$). La matrice $A \in \mathbb{R}^{2 \times 2}$ contient donc 4 paramètres d'excitation : 2 termes diagonaux (auto-excitation) et 2 termes hors-diagonale (excitation croisée).

2.1.1 Extension spatio-temporelle

Dans le cadre spatio-temporel, chaque événement est caractérisé par un triplet $(t_i, \mathbf{s}_i)$ où $t_i \in \mathbb{R}^+$ est son instant d'occurrence et $\mathbf{s}_i \in \mathbb{R}^2$ sa localisation géographique. L'intensité

conditionnelle du type k au point $(t, \mathbf{s})$ devient :

$$\lambda_k(t, \mathbf{s} \mid \mathcal{H}_t) = \mu_k + \sum_{l=1}^K \sum_{i: t_i^l < t} \alpha_{kl} \cdot \phi(t - t_i^l) \cdot \psi(\mathbf{s} - \mathbf{s}_i^l), \quad (6)$$

où le noyau spatio-temporel se factorise en un composant temporel $\phi(\cdot)$ et un composant spatial $\psi(\cdot, \cdot)$.

Noyau temporel exponentiel. Nous utilisons un noyau temporel exponentiel, classique dans la littérature :

$$\phi(\Delta t) = \beta e^{-\beta \Delta t}, \quad \Delta t > 0,$$

où $\beta > 0$ est le paramètre de décroissance temporelle. Ce noyau permet d'exprimer l'intensité de façon récursive, ce qui est exploité pour l'optimisation numérique.

Noyau spatial gaussien isotrope. L'influence spatiale d'un événement situé en $\mathbf{s}_j$ sur un point $\mathbf{s}$ est modélisée par un noyau gaussien isotrope :

$$\psi(\mathbf{s} - \mathbf{s}_j) = \frac{1}{2\pi\sigma^2} \exp\left(-\frac{\|\mathbf{s} - \mathbf{s}_j\|^2}{2\sigma^2}\right),$$

où $\sigma > 0$ est la portée spatiale en kilomètres. La combinaison des deux noyaux donne le noyau spatio-temporel complet :

$$g(\Delta t, \Delta \mathbf{s}) = \beta e^{-\beta \Delta t} \cdot \frac{1}{2\pi\sigma^2} \exp\left(-\frac{\|\Delta \mathbf{s}\|^2}{2\sigma^2}\right). \quad (7)$$

Paramètres du modèle. Au total, le modèle comporte 8 paramètres :

$$\Theta = (\mu_1, \mu_2, \alpha_{11}, \alpha_{12}, \alpha_{21}, \alpha_{22}, \beta, \sigma).$$

Pour simplifier, nous supposons que β et σ sont partagés entre tous les types de crime. Cette hypothèse de parcimonie peut être relaxée si les données le justifient.

2.2 Données et prétraitement

2.2.1 Description du jeu de données

Le jeu de données utilisé est le registre public des crimes déclarés à Chicago (*Chicago Crimes Dataset*), disponible sur le portail *Chicago Data Portal*. Il recense l'ensemble des incidents criminels signalés à la police de Chicago depuis 2001, avec pour chaque événement : la date et l'heure, le type de crime (*Primary Type*), la localisation géographique (latitude, longitude) et diverses métadonnées administratives.

Nous restreignons notre analyse au **mois de décembre 2015** et aux **deux types de crimes** suivants :

- **Theft** : vols (incluant vols à la tire, vols de véhicule, vols dans les commerces),
- **Battery** : agressions physiques (coups et blessures),




FIGURE 5 – Localisation des crimes à Chicago

2.2.2 Prétraitement

Conversion temporelle. Les dates, initialement au format MM/DD/YYYY HH:MM:SS AM/PM, sont parsées en objets `datetime`. L'origine temporelle t_0 est fixée au premier événement observé en décembre 2015. Le temps de chaque événement est ensuite converti en **heures écoulées depuis t_0** :

$$t_i = \frac{\text{Date}_i - t_0}{3600 \text{ secondes}}.$$

Travailler en heures plutôt qu'en secondes permet d'éviter des valeurs numériques de l'ordre de 10^6 qui peuvent déstabiliser l'optimiseur.

Perturbation aléatoire des temps coïncidents (*jitter*). Les données présentent un nombre non négligeable d'événements enregistrés avec la même estampille temporelle à la minute près, en raison de la granularité de l'enregistrement policier.

Or, les processus ponctuels supposent que les événements sont presque sûrement distincts. Pour régulariser cette situation, un bruit uniforme de faible amplitude est ajouté à chaque temps :

$$\tilde{t}_i = t_i + U_i, \quad U_i \stackrel{\text{i.i.d.}}{\sim} \mathcal{U}\left(0, \frac{1}{60}\right),$$

soit un jitter d'au plus 1 seconde (exprimée en heures), ce qui est négligeable à l'échelle des dynamiques criminelles étudiées (de l'ordre de l'heure) tout en garantissant l'injectivité temporelle.

Projection cartographique. Les coordonnées géographiques (latitude, longitude) en degrés décimaux sont projetées en coordonnées cartésiennes (x, y) en kilomètres à l'aide d'une projection conique conforme de Lambert, paramétrée pour la région de Chicago :

$$\text{travailler}(x_i, y_i) = \frac{1}{1000} \cdot \text{Proj}_{\text{LCC}}(\text{lon}_i, \text{lat}_i),$$

avec les paramètres $\phi_1 = 41.6\text{N}$, $\phi_2 = 42.0\text{N}$, $\phi_0 = 41.8\text{N}$, $\lambda_0 = -87.65\text{E}$. Cette projection est essentielle car le noyau spatial gaussien est défini sur des distances euclidiennes en kilomètres, travailler directement en degrés décimaux introduirait une distorsion géométrique significative.

Construction du tableau d'événements. Après prétraitement, chaque événement est représenté par un vecteur (t_i, x_i, y_i, k_i) où $k_i \in \{1, 2\}$ est l'indice du type de crime. Les N événements sont triés par ordre chronologique croissant. Les séquences par type $\{(t_i, x_i, y_i) : k_i = k\}$ sont extraites pour les étapes d'estimation.

2.2.3 Log-vraisemblance du processus ponctuel spatio-temporel

Pour un processus ponctuel spatio-temporel d'intensité $\lambda_k(t, \mathbf{s})$, la log-vraisemblance des observations $\{(t_i, \mathbf{s}_i, k_i)\}_{i=1}^N$ sur $[0, T] \times \mathcal{S}$ est :

$$\log \mathcal{L}(\Theta) = \sum_{i=1}^N \log \lambda_{k_i}(t_i, \mathbf{s}_i) - \sum_{k=1}^K \int_0^T \int_{\mathcal{S}} \lambda_k(t, \mathbf{s}) d\mathbf{s} dt. \quad (8)$$

Le premier terme est la somme des log-intensités aux points d'observation. Le second terme, appelé *compensateur* (ou intégrale de Papangelou), pénalise les intensités élevées sur toute la fenêtre spatio-temporelle.

Calcul du compensateur. Grâce à la factorisation du noyau (7) et au fait que ψ intègre à 1 sur $\mathbb{R}^2$, l'intégrale spatiale se simplifie et le compensateur se décompose en :

$$\begin{aligned} \int_0^T \int_{\mathcal{S}} \lambda_k(t, \mathbf{s}) d\mathbf{s} dt &= \mu_k \cdot T \cdot |\mathcal{S}_k| + \sum_{l=1}^K \alpha_{kl} \sum_{i: k_i=l} \int_{t_i}^T \beta e^{-\beta(t-t_i)} dt \\ &= \mu_k \cdot T \cdot |\mathcal{S}_k| + \sum_{l=1}^K \alpha_{kl} \sum_{i: k_i=l} (1 - e^{-\beta(T-t_i)}), \end{aligned} \quad (9)$$

où $|\mathcal{S}_k|$ est l'aire de la région d'observation du type k (en km^2), approximée par l'étendue du nuage de points.

2.2.4 Méthode d'optimisation

La log-vraisemblance (8) est maximisée par rapport au vecteur de paramètres $\Theta \in \mathbb{R}^8$ via l'algorithme **LBFGS-B**. Les contraintes imposées sont :

- $\mu_k > 0$ pour tout k (positivité des baselines),
- $\alpha_{kl} \in [0, 0.33]$ pour tout (k, l) (condition suffisante de stabilité, puisque $\rho(A) \leq \|A\|_1 \leq K \cdot \max_{kl} \alpha_{kl}$),
- $\beta > 0$ (positivité de la décroissance temporelle),
- $\sigma \in [0.1, 50]$ km (portée spatiale bornée).

La condition de stabilité $\rho(A) < 1$ est vérifiée explicitement à chaque évaluation de la fonction objectif ; si elle est violée, une pénalité $+10^{10}$ est retournée.

2.3 Résultats et discussion

2.3.1 Paramètres estimés

L'optimisation multi-départ a été conduite avec $n_{\text{start}} = 5$ initialisations aléatoires. Le tableau 2 résume la convergence des différents départs.

TABLE 2 – Convergence des 5 départs de l’optimisation L-BFGS-B

Départ	β_0 (h ⁻¹)	$t_{1/2}^{(0)}$ (h)	σ_0 (km)	$\log \mathcal{L}$ final
1	0.010	66.8	3.77	-11 138.7
2	0.561	1.2	5.16	-10 777.5
3	0.012	57.5	5.56	-10 575.7
4	0.018	38.0	5.46	-10 570.2
5	0.245	2.8	1.38	-10 616.6

Note : le départ retenu (en gras) est celui qui maximise la log-vraisemblance. La dispersion des valeurs finales confirme la multimodalité du paysage de vraisemblance et justifie la stratégie multi-départ.

TABLE 3 – Paramètres temporels et spatiaux estimés

Paramètre	Estimation	Interprétation
$\hat{\beta}$ (h ⁻¹)	0.0554	Taux de décroissance temporelle
$t_{1/2} = \ln 2 / \hat{\beta}$ (h)	12.52	Demi-vie de l’effet d’excitation
$\hat{\sigma}$ (km)	0.821	Portée spatiale du noyau gaussien
$\log \mathcal{L}$	-10 570.2	Log-vraisemblance au maximum
$\rho(\hat{A})$	0.9497	Rayon spectral de la matrice d’excitation

Paramètres temporels et spatiaux. Le tableau 3 présente les estimations des paramètres partagés $\hat{\beta}$ et $\hat{\sigma}$.

Intensités de fond. Le tableau 4 présente les intensités de fond estimées $\hat{\mu}_k$, exprimées en crimes par heure et par jour.

TABLE 4 – Intensités de fond estimées $\hat{\mu}_k$

Type de crime	$\hat{\mu}_k$ (crimes/heure)	$\hat{\mu}_k \times 24$ (crimes/jour)
Theft	2.88×10^{-4}	0.0069
Battery	2.36×10^{-4}	0.0057

Matrice d’excitation. Le tableau 5 présente la matrice d’excitation estimée $\hat{A} = (\hat{\alpha}_{kl})$. L’entrée (k, l) quantifie le nombre moyen de crimes de type k engendrés par un crime de type l dans un voisinage spatio-temporel proche.

TABLE 5 – Matrice d’excitation estimée $\hat{A}$ - $\hat{\alpha}_{kl}$ (type $l \rightarrow$ type k)

	Theft ($l = 1$)	Battery ($l = 2$)
Theft ($k = 1$)	0.7553	0.2485
Battery ($k = 2$)	0.2396	0.6434
<i>Ratio de branchement</i>	0.9950	0.8920

Note : le ratio de branchement d’un type source l est la somme de la colonne l , soit $\sum_k \hat{\alpha}_{kl}$. Il représente le nombre moyen de crimes (tous types confondus) engendrés par un crime de type l .

3 Analyse de dépendance et stratégie de pair trading sur les indices VIX et RVX

3.1 Présentation théorique des copules

3.1.1 Définition et intérêt des copules en finance

Les copules constituent un cadre naturel pour modéliser la dépendance entre variables aléatoires indépendamment de leurs distributions marginales. En finance, elles sont particulièrement utiles lorsque la simple corrélation linéaire ne suffit plus à décrire les mouvements observés entre actifs, notamment en présence de non-linéarités, d'asymétries ou de dépendances de queue.

Soient X et Y deux variables aléatoires de fonctions de répartition marginales F_X et F_Y . D'après le théorème de Sklar, il existe une copule $C : [0, 1]^2 \rightarrow [0, 1]$ telle que la fonction de répartition jointe de (X, Y) s'écrive

$$F_{X,Y}(x, y) = C(F_X(x), F_Y(y)). \quad (10)$$

Lorsque les marginales sont continues, cette décomposition est unique. La copule C contient alors toute l'information sur la structure de dépendance entre X et Y , tandis que F_X et F_Y décrivent séparément les comportements univariés.

Dans une perspective de *pair trading*, cette séparation est particulièrement pertinente. En effet, les actifs considérés peuvent posséder des distributions marginales différentes tout en partageant une dépendance relative exploitable. La copule permet précisément de détecter les configurations dans lesquelles l'un des actifs apparaît anormalement haut ou bas conditionnellement au niveau de l'autre.

3.1.2 Copules considérées

Dans cette étude, plusieurs familles de copules bivariées ont été comparées sur les pseudo-observations uniformes issues des log-rendements du VIX et du RVX .

Copule gaussienne : est définie par

$$C_{\text{Gauss}}(u, v; \rho) = \Phi_{\rho}(\Phi^{-1}(u), \Phi^{-1}(v)), \quad (11)$$

où Φ désigne la fonction de répartition de la loi normale standard, et Φ_{ρ} la fonction de répartition de la loi normale bivariée de corrélation ρ . Elle modélise une dépendance symétrique, sans dépendance de queue explicite.

Copule de Clayton : La copule de Clayton adaptée à des dépendances marquées dans la queue inférieure. Elle s'écrit :

$$C_{\text{Clayton}}(u, v; \theta) = (u^{-\theta} + v^{-\theta} - 1)^{-1/\theta}, \quad \theta > 0. \quad (12)$$

Copule de Gumbel : favorise une dépendance dans la queue supérieure. Elle est donnée par :

$$C_{\text{Gumbel}}(u, v; \theta) = \exp \left(- [(-\log u)^{\theta} + (-\log v)^{\theta}]^{1/\theta} \right), \quad \theta \geq 1. \quad (13)$$

Copule de Frank : modélise une dépendance symétrique, sans accent spécifique sur les queues. est définie par

$$C_{\text{Frank}}(u, v; \theta) = -\frac{1}{\theta} \log \left(1 + \frac{(e^{-\theta u} - 1)(e^{-\theta v} - 1)}{e^{-\theta} - 1} \right), \quad \theta \neq 0. \quad (14)$$

Copule de Joe. capture une dépendance plus marquée dans la queue supérieure. Elle est une copule archimédienne de la forme

$$C_{\text{Joe}}(u, v; \theta) = 1 - ((1 - u)^\theta + (1 - v)^\theta - (1 - u)^\theta(1 - v)^\theta)^{1/\theta}, \quad \theta \geq 1. \quad (15)$$

Copules $N13$ et $N14$. appartiennent à la famille des copules archimédiennes définies à partir d'une génératrice ϕ .

Dans le cas de la copule $N14$, la génératrice et la copule s'écrivent

$$\phi(t) = (t^{-1/\theta} - 1)^\theta, \quad \theta \geq 1,$$

$$C_{N14}(u, v; \theta) = \left(1 + \left[(u^{-1/\theta} - 1)^\theta + (v^{-1/\theta} - 1)^\theta \right]^{1/\theta} \right)^{-\theta}. \quad (16)$$

Dans notre étude, cette copule obtient le meilleur ajustement statique sur l'échantillon d'apprentissage.

3.2 Description des données

Nous considérons deux indices de volatilité implicite du marché actions américain : le VIX , associé au S&P500, et le RVX , associé au Russell 2000. Le premier reflète la volatilité anticipée du segment des grandes capitalisations, tandis que le second joue un rôle analogue pour les petites capitalisations. Ce couple est particulièrement pertinent pour une stratégie de *relative value*, car les deux indices réagissent conjointement aux épisodes de stress, tout en conservant des écarts structurels de niveau.

Les données journalières couvrent la période 2010–2025, scindée en un échantillon d'apprentissage statique [2010-01-01, 2020-12-31] et une période de trading [2021-01-01, 2025-12-31]. À partir des niveaux $P_t^{(VIX)}$ et $P_t^{(RVX)}$, nous définissons les log-rendements


$$r_t^{(VIX)} = \log P_t^{(VIX)} - \log P_{t-1}^{(VIX)}, \quad r_t^{(RVX)} = \log P_t^{(RVX)} - \log P_{t-1}^{(RVX)}. \quad (17)$$

Empiriquement, les deux séries présentent une forte dépendance, avec une corrélation des log-rendements de l'ordre de 0.921 et un coefficient de Kendall $\tau \approx 0.692$. Le ratio de niveau RVX/VIX restant variable dans le temps, cela suggère l'existence de désalignements relatifs potentiellement exploitables.

3.3 Méthodologie statistique

3.3.1 Ajustement des marges

La modélisation procède en deux étapes. Dans un premier temps, les distributions marginales des log-rendements du VIX et du RVX sont ajustées séparément. Plusieurs


FIGURE 6 – Niveaux journaliers du VIX et RVX sur l'échantillon d'apprentissage.

familles paramétriques sont comparées : loi normale, loi de Student, loi logistique généralisée et loi des valeurs extrêmes généralisée. Le choix final est effectué à l'aide des critères d'information AIC et BIC , complétés par un test de Kolmogorov–Smirnov.

Pour les deux séries, la loi de Student fournit le meilleur ajustement. Ce résultat est cohérent avec la présence de queues épaisses, typiques des séries financières de volatilité implicite.

Soient $\hat{F}_{VIX}$ et $\hat{F}_{RVX}$ les fonctions de répartition marginales ajustées. Les log-rendements observés sont alors transformés en pseudo-observations uniformes :

$$u_t = \hat{F}_{VIX}(r_t^{(VIX)}), \quad v_t = \hat{F}_{RVX}(r_t^{(RVX)}). \quad (18)$$

3.3.2 Sélection de la copule

À partir des pseudo-observations (u_t, v_t) , plusieurs copules sont ajustées par maximum de vraisemblance. Les critères AIC et BIC sont utilisés pour comparer les différentes familles. Sur l'échantillon d'apprentissage, la copule $N14$ obtient le meilleur ajustement, devant la copule gaussienne.

TABLE 6 – Comparaison des copules ajustées sur l'échantillon d'apprentissage.

Copule	Paramètre	Log-vraisemblance	AIC
$N14$	2.7254	2248.0242	-4494.0484
Gaussienne	0.8853	2180.5693	-4359.1386
Gumbel	3.1431	2160.9278	-4319.8558
$N13$	7.8703	1971.9176	-3941.8352
Frank	10.8850	1923.7452	-3845.4903
Joe	3.7776	1844.1061	-3686.2123
Clayton	3.1596	1743.7257	-3485.4514

En estimation roulante sur la période de trading, les copules les plus fréquemment sélectionnées sont les copules gaussienne et $N14$. La sélection n'est donc pas figée, mais la structure de dépendance reste globalement stable.

3.4 Construction de la stratégie de pair trading

3.4.1 Probabilités conditionnelles, règles de trading et rendement

La stratégie repose sur une estimation roulante des marginales et de la copule sur une fenêtre de 500 jours, utilisée ensuite pour produire des probabilités conditionnelles sur le bloc suivant de 100 jours. À chaque date t , on calcule

$$p_t^{(VIX)} = \mathbb{P}(U \leq u_t \mid V = v_t), \quad p_t^{(RVX)} = \mathbb{P}(V \leq v_t \mid U = u_t), \quad (19)$$

où (u_t, v_t) désignent les pseudo-observations uniformes associées aux log-rendements du VIX et du RVX . Ces probabilités quantifient la position relative de chaque indice dans la structure jointe estimée ; des valeurs extrêmes signalent un déséquilibre potentiel entre les deux actifs.

La stratégie adoptée est symétrique, avec seuil d'ouverture $c_{\text{open}} = 0.90$ et seuil de fermeture $c_{\text{close}} = 0.65$. Une position longue sur le VIX et courte sur le RVX , soit

$$(w_t^{(VIX)}, w_t^{(RVX)}) = (1, -1),$$

est ouverte lorsque

$$p_t^{(VIX)} < 1 - c_{\text{open}} \quad \text{et} \quad p_t^{(RVX)} > c_{\text{open}}. \quad (20)$$

Inversement, une position courte sur le VIX et longue sur le RVX ,

$$(w_t^{(VIX)}, w_t^{(RVX)}) = (-1, 1),$$

est ouverte lorsque

$$p_t^{(VIX)} > c_{\text{open}} \quad \text{et} \quad p_t^{(RVX)} < 1 - c_{\text{open}}. \quad (21)$$

Les positions sont clôturées lorsque les probabilités conditionnelles reviennent vers une zone moins extrême, c'est-à-dire lorsque

$$p_t^{(VIX)} > 1 - c_{\text{close}} \quad \text{ou} \quad p_t^{(RVX)} < c_{\text{close}}, \quad (22)$$

$$p_t^{(VIX)} < c_{\text{close}} \quad \text{ou} \quad p_t^{(RVX)} > 1 - c_{\text{close}}. \quad (23)$$

Si $r_t^{(VIX)}$ et $r_t^{(RVX)}$ désignent les log-rendements journaliers, alors le log-rendement du portefeuille est donné par

$$r_t^{(p)} = w_{t-1}^{(VIX)} r_t^{(VIX)} + w_{t-1}^{(RVX)} r_t^{(RVX)}, \quad (24)$$

où le décalage d'un jour sur les positions évite tout biais d'anticipation. Le rendement simple s'écrit

$$R_t^{(p)} = e^{r_t^{(p)}} - 1, \quad (25)$$

et la valeur cumulée du portefeuille est finalement définie par

$$V_t = \prod_{s \leq t} (1 + R_s^{(p)}). \quad (26)$$

TABLE 7 – Performances comparées sur la période 2021–2025.

Stratégie	Total return	APR	Sharpe	MaxDD
Pair trading VIX/RVX	0.931004	0.179394	0.883591	-0.218078
Long VIX	-0.356693	-0.104714	0.494933	-0.681268
Long RVX	-0.315423	-0.090646	0.330390	-0.606155

3.5 Résultats empiriques

3.5.1 Performances

Les performances de la stratégie sont comparées à deux expositions directionnelles simples, consistant à détenir uniquement le VIX ou uniquement le RVX sur la même période. Les résultats sont reportés dans le Tableau 7.

La stratégie de pair trading surperforme très nettement les deux expositions directionnelles. Alors qu'un investissement simple sur le VIX ou sur le RVX conduit à une performance cumulée négative sur la période considérée, la stratégie fondée sur les copules génère un rendement cumulé d'environ 93.1%, un rendement annualisé de 17.9%, un ratio de Sharpe de 0.884 et un drawdown maximal limité à environ 21.8%.

La Figure 7 montre l'évolution de la valeur cumulée du portefeuille ainsi que celle des deux indices traités individuellement. On observe que la stratégie reste relativement stable pendant une large partie de la période, puis connaît une accélération marquée en fin d'échantillon, tout en conservant une volatilité plus contenue que les expositions directionnelles.


FIGURE 7 – Performance cumulée de la stratégie de pair trading comparée aux expositions directionnelles sur VIX et RVX .

La stratégie reste néanmoins perfectible, car elle utilise des poids fixes sans *hedge ratio* dynamique. En outre, les coûts de transaction ne sont pas pris en compte dans cette première modélisation. Une extension naturelle consisterait à combiner le signal de copule avec un spread ou un ratio tel que RVX/VIX afin de filtrer les entrées.